

融合短时脉冲电压波形与人工特征的磷酸铁锂电池快速健康状态估计：编码器组合的受控比较

[第一作者]^a, [第二作者]^a, [通讯作者]^{a,*}

^a [院系, 单位, 城市 邮编, 国家]

* 通讯作者。电子邮箱: []

研究亮点

- 在统一的电芯互斥协议下对 15 种编码器组合进行基准比较。
- 片段化波形分支使 MLP 主干的误差降低 8.2%，并在 58/64 个电芯上取得改善。
- 编码器排序取决于组合方式，而非结构复杂度。
- 在未见循环工况和训练与测试匹配的传感器噪声下，波形增量依然存在。
- 仅需 3 个充电脉冲和 19k 参数的模型即可实现快速 SOH 估计。

摘要

短时电流脉冲可为锂离子电池健康状态（SOH）提供快速诊断，但学习得到的波形表征能否在人工脉冲特征之外提供增量信息，尚未在受控协议下得到检验。本文构建以人工特征与累计循环数为主干、101 点脉冲电压响应为补充分支的双分支模型，并在 64 个公开磷酸铁锂（LFP）/石墨电芯的 16,938 条脉冲记录上，采用 5 折电芯互斥交叉验证，评价 3 种主干编码器与 5 种波形编码器的全部 15 种组合。在各组合中，多层感知机（MLP）主干与片段化 Transformer（PatchTST）补充的组合取得最低的电芯宏平均均方根误差，为 1.377 个 SOH 百分点（95%置信区间 1.247~1.513）。相对不含波形的相同主干，误差降低 8.2%，64 个电芯中有 58 个改善；增益在 SOH 低于 80% 的区间最大（17.2%），波形在该区间部分修正了主干的收缩偏差。编码器排序依赖于组合：PatchTST 在 MLP 主干下排名第一，在另外两种主干下却排在末位；组合依赖项最多可解释组合间差异的 47.6%。进一步试验表明：波形增量在独立 NMC/石墨数据集上得到重复（误差降低 7.6%，44 个电芯中 39 个改善），并在未见循环工况和训练与测试匹配的传感器噪声下依然存在；循环数存在 $\pm 10\%$ 偏差时，误差至多增加 3.5%；3 个充电脉冲即可达到 6 脉冲协议的精度；推断需要 19,041 个参数，每条脉冲的计算量为 0.42 MFLOPs。因此，在基于脉冲的 SOH 估计中，编码器应作为组合、依据受控证据进行选择，而不能依据结构复杂度。

关键词：磷酸铁锂电池；健康状态；短时电流脉冲；特征融合；片段化 Transformer；电芯互斥验证

术语与符号

缩写	含义	符号	含义
BMS	电池管理系统	E_h, E_v	主干编码器与补充编码器
CNN	卷积神经网络	g	回归头
DCIR	直流内阻	K	所选人工特征数
DOD	放电深度	L, P, S	序列长度、片段长度、片段步长
GBDT	梯度提升决策树	M	片段数
GPR	高斯过程回归	Q_{ir}	电芯 i 在第 r 次 RPT 时的放电容量
LFP	磷酸铁锂	y_{ir}	实测 SOH (%)
MAE	平均绝对误差	$\hat{y}, \hat{y}^*$	预测 SOH 及其标准化值
MLP	多层感知机	$\Delta v_t, \tilde{v}_t$	首点作差脉冲电压与标准化脉冲电压
NMC	镍钴锰氧化物	h	主干输入向量
PW-Trans.	逐点 Transformer	$n_{i,r}, \tau$	累计循环数及其标准化值
RBF-SVR	径向基函数核支持向量回归	λ	单调惩罚权重
RevIN	逐样本实例归一化	ρ_j	特征 j 与 SOH 的 Spearman 秩相关系数
RMSE	均方根误差	σ_{noise}	所加电压噪声的标准差
RPT	参考性能测试	R0	主配置 (MLP + PatchTST)
SOC, SOH	荷电状态、健康状态	A1–A4, D1–D3, P1–P3	消融配置 (3.5.1 节)
TCN	时间卷积网络	pp	SOH 百分点

1 引言

电动汽车和储能系统中的锂离子电池在整个服役期内持续老化。健康状态 (SOH) 评估对于估计可用能量和功率、安排维护以及决定梯次利用至关重要[1–3]。容量型 SOH 定义为电池当前容量与初始容量之比，直接测量需要在受控条件下进行完整充放电。这类测试通常耗时数小时并中断电池正常运行，难以在现场频繁开展[4,5]，因此 SOH 须借助获取更快的信号来推断。已有数据驱动方法分别基于差分曲线、部分充电曲线、电压弛豫、电化学阻抗谱 (EIS) 和短时电流脉冲。这些方法大多对运行条件要求苛刻，如长时间采集数据、受控的完整循环或专用激励硬件[1,4,6,8–11]；例如差分曲线的特征峰还会被传感器噪声和磷酸铁锂 (LFP) 电芯平坦的电压平台所模糊[7]。这些条件在实验室之外难以满足。短时电流脉冲是一个例外。电流脉冲实质上是一种时域阻抗测量[12]，在适当的测试条件下，其响应甚至可用于重构阻抗谱[13]。锂库存损失、活性材料损失和界面膜生长等老化模式都会改变脉冲响应，使其随老化而演变[12,14]；基于脉冲的特性测试也已是电池测试中的标准手段[15]。完整的混合脉冲功率特性测试序列可能超过 12 h[17]，而单次脉冲只持续数秒至数分钟，只需一个受控的电流阶跃，因此脉冲测试是估计容量的快速、实用途径[16]。对于 LFP 电芯，脉冲响应以动力学过电位为主，即使在平衡电压几乎不变的区间，其随老化的变化仍然可测。

数据驱动的 SOH 估计依赖从电压、电流、温度或阻抗测量中提取的输入特征，不同研究依电池类型、工况和模型结构采用不同形式，包括电压曲线、增量容量或差分电压曲线、统计量、频域指标和模型参数。在电池管理系统（BMS）中部署还带来额外约束：推断须在资源受限的硬件上实时运行，而黑箱行为会削弱安全相关决策的可信度[18,19]。按获取方式，输入可分为两类[21,22]。一类从电压、电流、温度或增量容量曲线中提取人工健康指标，作为回归模型的输入[3]；这些指标具有物理可解释性，但依赖专家经验，且难以迁移到不同工况[21,22]。另一类由深度网络直接从原始序列中学习表征，免去了人工特征设计，但可解释性有限，其性能很大程度上取决于网络结构与任务的匹配程度[18,22]。多分支模型可通过融合多种输入表征兼顾两者的优点[23–25]；然而其编码器在设计时即已固定，对比评价主要针对基线模型和融合策略，而非对分支编码器的系统比较[24,25]。在一致协议和严格交叉验证下的系统比较也仍然有限[26]，部分基准研究只考虑单一输入类型[27]。因此，特征提取方式尚无共识；这种分散局面加上缺乏标准评价协议，使不同方法难以在同一基础上比较，也难以迁移到新的电池或实际 BMS 中[20]。

在基于短时电流脉冲的 SOH 估计中，现有研究各自只使用一种输入表征：Li 等[16]和 Nowacki 等[28]使用原始脉冲响应，Tao 等[17,29]和 Ran 等[30]则以从响应中提取的特征进行回归，跨 SOC 的迁移也已有研究[31]。这些研究证实短时脉冲含有与 SOH 相关的信息，但对于如何提取特征、哪种表征更优仍无共识。具体而言，有三个问题尚不清楚。第一，各分支编码器的主效应未知，包括人工特征采用更复杂的编码器能否提升性能。第二，编码器组合尚未被考察：波形编码器的表现可能取决于与之搭配的人工特征编码器，而只改变一个分支的比较无法发现这种依赖。第三，不同研究在输入信息[32–34]、数据划分与预处理[35,36]和训练设置[26]上存在差异，且缺乏公共基准[37]，限制了研究间的可比性。因此，需要在统一协议下同时改变两个分支的编码器、评价全部组合。这一问题也关系到部署：若更复杂的编码器并无收益，资源受限的 BMS 就应优先采用轻量结构。

人工特征与原始波形的融合可以改善 SOH 估计[23–25,42]。然而，已有研究融合的是来自不同测量的信号[42,43]或同一信号的不同变换[24,25]，很少涉及同一脉冲所得人工特征与原始波形的融合；针对单个短时脉冲的补充编码器设计也很少受到关注。以人工特征作为主分支是 SOH 估计中的常见做法[3,17,29,30]。人工特征物理意义明确，适合轻量模型[21]，符合 BMS 对可解释性和成本的要求；原始波形所缺少的上下文（如使用历史）也可以作为显式特征加入。然而，人工特征是对响应的压缩：每项特征只描述一种预先定义的性质，难以保证覆盖各工况下所有与老化相关的变化[22]。此外，多数人工特征是逐项计算的差值、统计量或频域量，难以刻画瞬态不同部分之间的联合变化。学习型编码器可以直接从原始波形中提取这类形状信息，包括人工特征未覆盖的信息。但单独使用时，学习型编码器的可解释性有限[18]，原始波形也不含工况和使用历史信息。因此，学习型波形编码器更适合作为人工特征的补充，而非替代。

对于波形分支，片段化编码器是有前景的候选。PatchTST 将连续片段编码为标记，并通过自注意力建立片段之间的联系[40]，可能与逐项计算的特征形成互补。然而，它原本是为长序列预测设计的[40]。在电池研究中，PatchTST 已用于 SOH 估计[44]、寿命预测[45]和电压预测[46]，但如何将其改造用于短时脉冲输入和标量健康状态估计仍未被研究。

针对上述问题，本文在统一实验协议下构建波形编码器与人工特征编码器的完整比较矩阵，各组合采用相同的数据划分、预处理和训练预算。矩阵包括卷积、全连接、时间卷积[38]、逐点注意力[39]和片段化[40]5 种结构的波形编码器，以及多层感知机（MLP）、ResNet 和 FT-Transformer[41]3 种人工特征编码器，全部组合均以电芯互斥交叉验证进行比较。与预先选定分支编码器的融合研究[23–25]或只使用单一输入模型比较[27]不同，该设计可以估计主效应、检验编码器组合依赖，并将误差差异归因于编码器本身。在比较矩阵的基础上，本文构建双分支模型：主分支为人工特征分支，由 MLP 编码，并纳入工况上下文和累计循环信息；补充分支为片段化波形表征，并给出将 PatchTST 由时间序列预测改造用于标量 SOH 估计的具体方案。两个分支在后期融合。为体现容量随循环总体下降的规律，本文对预测 SOH 关于累计循环数施加单调软约束；与基于退化动力学、机理特征或数字孪生的方法[47–49]不同，该约束不需要机理模型。消融实验和电芯层级的统计分析量化了各设计因素的贡献。

本文的主要贡献如下：

（1）在统一实验协议下构建波形编码器与人工特征编码器的完整比较矩阵，在相同的数据划分、预处理和训练预算下，可比地评价各编码器的主效应及其组合依赖。

（2）构建基于短时电流脉冲的双分支 SOH 估计模型，以人工特征分支为主、片段化波形表征为补充，纳入工况上下文和累计循环信息，并给出 PatchTST 用于标量 SOH 估计的具体改造方案。消融实验和电芯层级的统计分析分离出各设计因素的贡献，并明确波形分支发挥作用的条件。

（3）在留出循环工况、循环数误差与传感器噪声、精简脉冲协议以及独立的镍钴锰（NMC）/石墨数据集上检验模型的通用性，其中波形增量在 NMC 数据集上得到重复，并量化了模型的归因与计算开销。

2 数据与统一实验协议

为使编码器之间的误差差异能够归因于结构本身，全部模型共用同一数据协议：清洗规则、电芯划分、两分支的输入政策以及训练折内的特征筛选与缩放，在 15 种编码器组合和全部补充实验中保持一致（表 1）。

2.1 数据来源、脉冲协议与健康状态定义

公开的 UConn-ISU-ILCC LFP/Gr 电池老化数据集[28]包含 64 个标称容量为 1.2 Ah 的磷酸铁锂/石墨功率型电芯，分 11 种循环工况老化，各工况在恒流–恒压（CC–CV）充电倍率（2C~

3.25C)、恒流放电倍率(1.5C或2C)和放电深度(DOD, 60%~100%)上不同(补充表S1)。老化过程约每100次循环中断一次,开展参考性能测试(RPT),测量剩余容量并施加短时脉冲[28,31]。全部老化试验与RPT均由数据发布方完成,本文仅对数据进行再分析。

每个RPT在三个SOC下各施加一次充电脉冲和一次放电脉冲。单次脉冲依次为0.2C电流30s、1C电流10s和静置60s(图1a)[31],持续100s,通过的电量约为标称容量的0.44%。脉冲以预设的电压截止点触发,因此20%、50%和90%是寿命初期对应的名义SOC,随着容量衰减,实际SOC会逐渐偏离名义值[31]。每个RPT由此得到六个工况(三个名义SOC×两个方向)的记录。在1Hz记录中,电流阶跃处的电压跃变主要反映欧姆电阻与快速的电荷转移过程,恒流期间电压的持续变化还包含扩散的贡献,静置段的缓慢恢复则以扩散弛豫为主[12](图1b、c)。0.2C段与1C段末点之间的电压差给出10s直流内阻(DCIR),供2.3.2节使用。

SOH以同一电芯首次RPT的放电容量为归一化基准:

$$y_{ir} = 100 \times \frac{Q_{ir}}{Q_{i0}} \quad (1)$$

式中, Q_{ir} 为电芯 i 在 RPT r 下的放电容量。因此, SOH 表示相对于初始测量值的容量保持率,而非相对于额定容量的保持率。该容量来自 RPT 中的完整参考放电,即脉冲诊断旨在替代的、耗时以小时计的测试;它仅用作标签,由它派生的任何量均不进入模型(2.3.2节)。

每条记录包含101个电压采样点:第0点为施加电流前的最后一个电压值,其后30s、10s与60s三段由发布方处理代码经分段三次 Hermite 插值重采样至1Hz[31]。插值点不视为独立样本。每次推理使用一条脉冲记录,即一次100s的测试。主指标将同一RPT内六条单记录预测取平均,对应三个名义SOC下的联合诊断,其耗时还包括将电芯调整至各SOC的时间;单工况误差另行报告(4.3节)。




图1 数据集与脉冲响应。(a) 充电（实线）与放电（虚线）脉冲的程控电流：C/5 电流 30 s、1C 电流 10 s、静置 60 s。(b, c) 50%名义 SOC 下相对脉冲前电压的平均电压响应 ΔV ，按实测 SOH 分组（颜色越深表示 SOH 越低）；插图放大了 1C 段末端与弛豫起始处，该处过电位随老化增大。(d) 64 个电芯的实测 SOH 随累计循环数的变化，按放电深度着色；折线连接实测 RPT，不作插值。

2.2 数据清洗与电芯互斥划分

清洗前共有 17,130 条记录，分属 2,855 个电芯-RPT 组。记录只有通过全部预设检查才予保留：

$$A = \left\{ (V, x, y) : \begin{array}{l} V_t \in [2.5, 4.5] V \quad \forall t; \max_t V_t - \min_t V_t \in [0.005, 0.5] V; \max_t |V_{t+1} - V_t| \leq 0.1 V \\ y \in [0, 110]; q_{miss} \leq 0.20; |G_{i,r}| = 6; \max_{g \in G_{i,r}} y_g - \min_{g \in G_{i,r}} y_g \leq 10^{-5} \end{array} \right\} \quad (2)$$

式中， V_t 为第 t 个电压采样点， y 为百分数形式的 SOH， q_{miss} 为人工特征的缺失比例， $G_{i,r}$ 为电芯 i 在 RPT r 下的六条工况记录。被剔除的 192 条记录均因循环计数不是有限值：发布方数据缺少第 42 次 RPT 的循环计数，涉及全部到达该 RPT 的 32 个电芯（32 个完整电芯-RPT 组）。其余 16,938 条记录构成 2,823 个完整组，覆盖全部 64 个电芯，SOH 范围为 72.34%~100%（图 1d）。上述阈值均预先设定并记入日志，未根据测试误差调整。

采用划分种子 42 构造 5 个外层测试折：先置乱 64 个电芯编号，再划分为 5 个互斥测试集合。在每折的非测试电芯中，以折序号为偏移、步长为 5 抽取验证电芯，其余电芯用于训练，五

折的训练/验证/测试电芯数依次为 40/11/13、41/10/13、41/10/13、41/10/13 与 42/10/12。同一电芯的所有 RPT 与工况记录整体分配，因为按记录随机划分会高估精度[36]。全部实验采用同一划分，并以 MLP 主干+PatchTST 补充作为参考配置 R0。

表 1 数据、输入与实验设计

项目	设置
数据	公开 UConn-ISU-ILCC LFP/Gr 数据集；64 个电芯，16,938 条记录，2,823 个电芯-RPT 组
脉冲工况	名义 SOC 20%、50%、90% × 充电、放电；单次脉冲 100 s
波形分支	101 点 ΔV，逐位置训练折标准化
主干分支	训练折筛选的 50 项特征（49 项波形衍生量+DCIR）+ 累计循环数 τ
排除的输入	库仑计 SOC 及其偏差（由参考容量派生）；同一 RPT 的其他记录；历史容量；电芯编号
验证	5 个电芯互斥外层折；初始化种子 0、1、2
编码器比较矩阵	5 种波形编码器 × 3 种主干编码器 × 5 折 × 3 种子 = 225 次训练
其他实验	19 个神经网络配置 × 15 = 285 次训练；30 个已有方法复现模型；传统回归器（3.5 节）
主指标	同一 RPT 六工况预测平均后的电芯宏平均 RMSE

2.3 人工特征主干输入

2.3.1 候选特征族

人工特征分支是模型的主干。150 项候选特征中，143 项由单条脉冲的电压计算，7 项描述工况与年龄（表 2）。波形衍生特征沿用发布方的脉冲时序，分别作用于 30 s 小电流段、10 s 大电流段、60 s 静置段和全序列，分为六族，每项特征都有确定的计算窗口和公式（补充说明 S1）。这些特征均为逐项计算：瞬态边界量虽跨越相邻区段，但只比较预先指定的采样点对，并不刻画整个瞬态中的联合形状变化，这也是本文设置波形补充分支的原因（2.4 节）。

表 2 人工特征候选族及其在第 0 折训练电芯上的入选情况

特征族	候选数	计算窗口	刻画内容	入选数
分段统计量	45	30 s、10 s、60 s 三个区段	电压水平、离散度、形状、熵与线性趋势	9
全局波形量	24	全序列	整体统计量、端点与分位数	7
差分动力学量	22	一阶、二阶差分	电压变化速率及其变化	14
瞬态边界量	18	指定采样点对	电流阶跃处跃变、净变化与响应时间	2
频域与小波量	24	去均值加窗的序列	谱线幅值、频带能量、谱形与小波能量	16
非线性复杂度量	10	全序列	自相关、Hjorth 参数、熵与 Hurst 指数	1
工况与年龄上下文	7	记录元数据	名义 SOC 与库仑计 SOC、偏差、方向、DCIR、累计循环数、RPT 序号	1 ^a
合计	150			50

^a 匹配工况直流内阻。五折中 47 项特征在每折均入选，54 项至少在一折中入选。库仑计 SOC、SOC 偏差、累计循环数与 RPT 序号不参与筛选（2.3.2 节）。

2.3.2 工况上下文与累计循环数

单条脉冲不包含累计使用信息，其起始 SOC 又随老化漂移，因此主干另设 7 项上下文候选：

$$\left[\frac{SOC_{nom}}{100}, \frac{SOC_{coul}}{100}, \frac{SOC_{coul} - SOC_{nom}}{100}, \pm 1, DCIR_{pulse, SOC}, n_{i,r}, r \right] \quad (3)$$

依次为名义 SOC、库仑计 SOC、二者偏差、脉冲方向、匹配工况直流内阻、累计循环数与 RPT 序号。发布方按同一脉冲两级电流之间的电压差计算直流内阻，即 $R = |V_{40} - V_{30}| / (1.2 A - 0.24 A)$ [31]，其中 V_{30} 与 V_{40} 分别为 0.2C 段与 1C 段的末点采样值。该量只依赖单条脉冲，对应第 1 节所述与功率能力相关的电阻，并参与特征筛选。

库仑计 SOC 及其与名义 SOC 的偏差被剔除。发布方代码以脉冲起点处的累计电量除以同一 RPT 参考放电测得的容量 [31]，而该容量正是式 (1) 中 SOH 标签的分子；因此这两项均由标签派生，在不开展完整容量测试时无法获得。名义 SOC 与脉冲方向保留为候选，但由于每个 RPT 均包含全部六个工况，二者与 SOH 的秩相关为零，从未入选；脉冲方向另可由波形输入的符号直接看出。

累计循环数不参与筛选，而是单独标准化为输入 τ (2.5 节)；RPT 序号予以剔除，以免年龄信息重复。循环数 $n_{i,r}$ 由相邻 RPT 之间的循环间隔累加得到。由于第 42 次 RPT 的间隔缺失，受影响的 32 个电芯在其后的 494 个电芯-RPT 点上少计一个间隔 (67~118 次循环，中位数 85 次，即寿命的 1.3%~2.3%)；图 1d 与模型采用同一规则。使用 τ 需要获取电芯的循环记录，这限定了模型的适用范围。

2.3.3 训练折内特征筛选

剔除累计循环数、RPT 序号以及两项由标签派生的 SOC 量后，剩余 146 项可选特征。每折仅用训练记录计算各特征与 SOH 的 Spearman 秩相关：

$$\rho_j = \frac{\sum_i (r_{ij} - \bar{r}_j)(r_i^y - \bar{r}^y)}{\sqrt{\sum_i (r_{ij} - \bar{r}_j)^2 \sum_i (r_i^y - \bar{r}^y)^2}} \quad (4)$$

式中， r_{ij} 与 r_i^y 分别为特征 j 与标签的秩。按 $|\rho_j|$ 降序贪心选取特征，若候选特征与任一已选特征的秩相关绝对值达到 0.98 则跳过：

$$S \leftarrow S \cup \{j\} \text{ if and only if } \max_{i \in S} |\rho_{ji}^{rank}| < 0.98 \text{ and } |S| < K \quad (5)$$

若通过的特征不足 K 项，则在其余相关系数有限的特征中按 $|\rho_j|$ 降序补足，此时不再施加冗余约束。五折各选出 50 项特征，其中 47 项在五折中均入选（并集 54 项），因此筛选结果对训练电芯的变化较为稳定。第 0 折中，频域与小波量（16 项）和差分动力学量（14 项）占主导（表 2），直流内阻在每折中均排在第 13~14 位。主频与 85% 频谱滚降频率在部分折的训练电芯内为常数而被跳过，因此最多可对 144 项特征排序。 $K=50$ 的取值依据见 4.5.3 节。

2.4 波形补充输入

波形分支只接收单条脉冲的电压序列，不含工况与年龄信息。序列 $V_0, \dots, V_{100}$ 相对首点作差：

$$\Delta v_t = V_t - V_0, t=0, 1, \dots, 100 \quad (6)$$

该处理去除了起始电压，使序列表示脉冲引起的极化响应，即在平坦的 LFP 电压平台上仍可测量的、受动力学控制的部分。随后用训练折统计量对每个位置分别标准化：

$$\tilde{v}_t = \frac{\Delta v_t - \mu_t^w}{\sigma_t^w} \quad (7)$$

从而保留全部 101 点的完整瞬态，由波形编码器学习人工特征未覆盖的区段间形状信息。

2.5 填补、标准化与输入信息核查

缺失值以训练折同列有限值的中位数填补，再进行标准化：

$$m_j = \text{median}\{x_{ij} : x_{ij} \in R\}, \tilde{x}_{ij} = \begin{cases} x_{ij}, & x_{ij} \in R \\ m_j, & x_{ij} \notin R \end{cases}, z_{ij} = \frac{\tilde{x}_{ij} - \mu_j}{\sigma_j} \quad (8)$$

累计循环数经标准化后与 K 项筛选特征拼接：

$$n_{i,r} = \sum_{q \leq r} \Delta c_{i,q}, \tau = \frac{n_{i,r} - \mu_n}{\sigma_n}, h = [z_1, \dots, z_K, \tau]^T \in R^{K+1} \quad (9)$$

当 $K=50$ 时，主干输入为 51 维。标签先除以 100 再标准化，预测值经逆变换还原：

$$y^* = \frac{y/100 - \mu_y}{\sigma_y}, \hat{y} = 100(\sigma_y \hat{y}^* + \mu_y) \quad (10)$$

式（4）、（5）与（7）～（10）中的全部统计量均仅由训练折拟合。除累计循环数外，所有输入均由单条脉冲得到；同一 RPT 的其他工况记录、历史容量、电芯编号以及由参考容量派生的量均不进入模型（补充表 S2）。

3 模型与实验设计

3.1 总体框架

模型由人工特征主干编码器 E_h 、波形补充编码器 E_v 和回归头 g 组成（图 2）。主干接收式（9）定义的 51 维输入 h ，补充分支接收式（7）定义的 $\tilde{v}$ ；两路输入均由同一条脉冲记录导出，其中 τ 另需该电芯的循环记录。两个编码器各输出 32 维表征，拼接后映射为标准化 SOH：

$$\hat{y}^* = g([E_v(\tilde{v}); E_h(h)]) \quad (11)$$

两个分支的差别体现在输入信息上：主干携带由脉冲计算的物理描述量（如直流内阻）和累计使用信息，单独即可完成 SOH 估计；补充分支只接收电压响应的形状。因此，补充分支以其

在主干之上带来的增量来评价（4.2 节）。在编码器比较矩阵中，3 种主干候选与 5 种补充候选两两交叉组合，其余部分均保持不变。




图2 双分支 SOH 估计模型（R0 配置）。左上：人工特征主干；训练折筛选的 50 项特征与标准化累计循环数 τ 组成 51 维输入，经 MLP 编码为 32 维表征。左下：波形补充；101 点脉冲电压响应经首点作差与逐位置标准化后，划分为 24 个片段（片段长度 $P=9$ ，步长 $S=4$ ），由单层 PatchTST 编码为 32 维表征。右：两路表征拼接为 64 维，经回归得到标准化 SOH $\hat{y}^*$ ，再经逆标准化输出。训练最小化均方误差与正偏导 $\partial \hat{y}^* / \partial \tau$ 惩罚项之和（ $\lambda = 0.1$ ）；该软约束仅在训练中起作用。

3.2 主干编码器

本文比较 3 种主干编码器。MLP 将 51 维输入依次映射为 64 维与 32 维，每层后接层归一化和 ReLU，第一层后设置 0.2 的随机失活（5,600 个参数）。ResNet 与 FT-Transformer 沿用面向表格数据的参考实现[41]，并在相近参数预算内调整为 32 维输出：ResNet 含 2 个宽度为 28 的残差块（5,800 个参数）；FT-Transformer 将每个输入量映射为宽度 20 的标记，含 1 个 4 头 Transformer 块和隐藏宽度 26 的 ReGLU 前馈层（6,124 个参数）；二者的随机失活率均为 0.2。三种编码器接收完全相同的输入； τ 以独立张量传入后再拼接，以便计算预测对 τ 的偏导（3.4 节）。

3.3 波形编码器与 PatchTST 适配

5 种补充编码器均将 101 点标准化序列映射为 32 维表征，末端统一为线性投影、ReLU 与 0.2 随机失活（表 3）。卷积神经网络（CNN）含 3 个卷积层（通道 $1 \rightarrow 16 \rightarrow 32 \rightarrow 64$ ，卷积核 7、5、3，各接批归一化与 ReLU，前两层后最大池化），其后为全局平均池化；MLP 依次映射 $101 \rightarrow 64 \rightarrow 48 \rightarrow 32$ ；时间卷积网络（TCN）[38] 宽度为 24，含 3 个膨胀率依次为 1、2、4 的残差

块，对完整脉冲使用对称填充，而非严格因果卷积；逐点 Transformer (PW-Trans.) [39]将 101 个采样点各视为一个标记（宽度 24，1 层，4 头），并对全部标记作均值池化。

PatchTST 最初用于长序列时间序列预测[40]，本文沿用其片段化思想。将长度为 $L=101$ 的序列按片段长度 P 、步长 S 划分为重叠片段，片段数为

$$M = \text{floor}\left(\frac{L-P}{S}\right) + 1, p_m = (\tilde{v}_{|m-1|S}, \tilde{v}_{|m-1|S+1}, \dots, \tilde{v}_{|m-1|S+P-1})^T \in R^P \quad (12)$$

取 $P=9$ 、 $S=4$ 时， $M=24$ ，最后一个片段恰好结束于第 101 个采样点，无需补零或截断。每个片段经线性映射升维至 $D=32$ ，并叠加可学习的位置嵌入，再由单层后置层归一化 Transformer 编码层（4 头，GELU 前馈宽度 64，随机失活 0.2）建模片段级依赖；随后经层归一化、跨标记均值池化与线性投影得到 32 维表征（补充说明 S2）。片段化先在局部窗口内联合表示相邻采样点，再由注意力建模区段之间的关系，使标记数由 101 降至 24；该分支共 10,752 个参数。

相对原始 PatchTST[40]，本文针对单条短脉冲的单值回归作了四处改动。（i）以均值池化加线性投影取代展平预测头，使表征维度与片段数无关；若改用展平预测头，该分支参数量将增至 34,304（模型总计 42,593）。（ii）不采用逐样本实例归一化（RevIN），以保留响应幅值：该幅值随内阻变化，可能携带老化信息。（iii）输入为 2.4 节所述经首点作差与逐位置标准化的单通道序列，而非原始电压。（iv）只保留单层编码器，不包括多步预测头和自监督预训练。改动（i）～（iii）通过逐项还原的方式加以检验（4.5.2 节）。

表 3 主干与补充编码器的结构及参数量

模块	编码器	主要设置	参数量
人工特征主干	MLP	51 → 64 → 32；层归一化，ReLU；第 1 层后随机失活 0.2	5,600
人工特征主干	ResNet	2 个残差块；宽度 28；隐藏宽度 28	5,800
人工特征主干	FT-Transformer	1 个块；标记宽度 20；4 头；ReLU 宽度 26	6,124
波形补充	CNN	通道 1 → 16 → 32 → 64；卷积核 7、5、3；池化后投影	11,232
波形补充	MLP	101 → 64 → 48 → 32；层归一化，ReLU，随机失活	11,440
波形补充	TCN	宽度 24；3 个残差块；膨胀率 1、2、4；对称填充	11,744
波形补充	逐点 Transformer	101 个标记；宽度 24；4 头；1 层；前馈宽 48	8,192
波形补充	PatchTST	24 个片段；宽度 32；4 头；1 层；前馈宽 64；均值池化投影	10,752
回归头	MLP	两路拼接（2 × 32）；64 → 32 → 16 → 1	2,689

组合的总参数量为主干、补充与回归头三部分之和：15 种组合在 16,481～20,557 之间，R0 为 19,041。

3.4 回归头、损失函数与训练设置

回归头将 64 维拼接向量经 64 → 32 → 16 → 1 的全连接层映射，第一层后接层归一化、ReLU 和 0.2 随机失活，第二层后接 ReLU（2,689 个参数）。因此，R0 共有 5,600 + 10,752 + 2,689 = 19,041 个参数；全部 15 种组合的参数预算相近（16,481～20,557），从而限制了模型规模对比较结果的影响。线性层权重采用 Xavier 均匀初始化，偏置置零。

训练目标由标准化 SOH 的均方误差和关于 τ 的正偏导惩罚组成：

$$L = MSE(\hat{y}^*, y^*) + \frac{\lambda}{B} \sum_{b=1}^B [\partial \hat{y}_b^* / \partial \tau_b]_+^2 \quad (13)$$

式中， B 为小批量大小， $[x]_+ = \max(0, x)$ ， $\lambda = 0.1$ 。该项抑制其余输入固定时预测随 τ 增加而上升的倾向，以不依赖机理退化模型的方式引入“容量随循环衰减”的先验。由于电压响应和人工特征也随老化改变，偏导非正并不能保证沿实测轨迹的预测单调，因此该惩罚属于软约束，其在轨迹层面的效果在 4.5.1 节检验。

全部神经网络采用 AdamW 优化器（学习率 10^{-3} ，权重衰减 10^{-4} ），批量大小 256，最多 100 轮，梯度范数裁剪阈值 5。ReduceLROnPlateau 调度（耐心 5 轮，衰减因子 0.5）、耐心 15 轮的早停以及最佳轮次选择均以验证电芯上的电芯宏平均均方根误差（RMSE）为监测指标。每个配置在 5 个外层折上分别以初始化种子 0、1、2 训练；小批量打乱使用独立的随机数发生器（种子 + 10,000），并启用确定性 CUDA 内核，因此每次运行均可逐位复现。训练在 NVIDIA GeForce RTX 5060 Laptop GPU 上完成；完整流程见补充算法 S1。

3.5 消融配置与对照模型

3.5.1 R0 的消融与敏感性配置

分支消融检验两个分支各自的必要性（补充表 S3）。A2 只保留主干（含 τ 与单调惩罚），其 32 维表征进入 $32 \rightarrow 32 \rightarrow 16 \rightarrow 1$ 的回归头（7,265 个参数），是评价波形增量的直接参照。A1 只保留 PatchTST 分支，并将直流内阻与 τ 直接拼接至 $34 \rightarrow 32 \rightarrow 16 \rightarrow 1$ 的回归头（12,481 个参数）。因素消融去掉单调惩罚（ $\lambda = 0$ ，A3），并在此基础上进一步去掉 τ （A4，主干输入为 50 维）。片段参数在 2×2 网格上比较：P1（5, 2）、P2（5, 4）、P3（9, 2）与 R0（9, 4）。适配消融每次只将 3.3 节的一处改动还原：D1 改用展平预测头，D2 在分片前加入带可学习仿射参数的 RevIN，D3 以原始电压代替 Δv （保留逐位置标准化）。最后，人工特征数量 K 在 {10, 20, 30, 50, 75, 100, 144} 上变化，其中 144 为可排序候选特征的数量。

3.5.2 传统回归器与信息来源对照

为检验主干是否必须由神经网络编码，本文在与 A2 完全相同的 51 维输入上训练 5 种传统回归器：岭回归、随机森林、直方图梯度提升决策树（GBDT；采用 scikit-learn 实现，与 LightGBM 属同类算法）、径向基核支持向量回归（RBF-SVR）和高斯过程回归（GPR）。超参数在验证电芯上从预设网格中选择（补充说明 S3），选定后不在训练与验证电芯上重新拟合。为分离信息来源，另以岭回归、随机森林和 GBDT 分别训练只用 τ 以及只用 50 项特征而不含 τ 的对照模型。

3.5.3 已有脉冲模型的复现

本文按 Nowacki 等[28]公开代码的默认设置，在本文的电芯划分与评价指标下复现其只用原始脉冲的模型：输入为 101 点 Δv ，输入与目标均以训练集统计量标准化；网络为含 5 个隐层、每层 100 个 tanh 神经元的 MLP，采用 Adam 优化器训练（学习率 0.0015，批量 50，最多 500 轮，按训练损失早停，耐心 5 轮）。每个脉冲方向训练一个模型，覆盖全部 SOC；原模型为多输出模型，本文只保留其 SOH 输出（共 30 个模型）。

3.5.4 强主干之上的波形增量

由于波形增量可能取决于主干的强弱，本文以 3.5.2 节选定的 GBDT 为主干，令神经网络学习其残差。训练电芯的残差由 4 折电芯互斥的折外预测得到，以免残差因样本内拟合而偏小；验证与测试电芯的残差使用在全部训练电芯上拟合的 GBDT。残差学习器 G+R0、G+A2 和 G+A1 分别与 R0、A2 和 A1 的结构和训练设置相同，以标准化后的残差为目标，最终预测为 GBDT 预测与残差预测之和。因此， $(G+R0) - (G+A2)$ 即 GBDT 主干之上的波形增量。另作一项事后补充：将 101 点标准化电压直接追加到 GBDT 与 SVR 的输入中，并重新调参。

3.5.5 泛化性、稳健性与部署实验

另设五项实验考察模型的适用范围。（i）未见循环工况：11 个循环工况组依次留出（留一工况组验证），验证电芯从其余工况组中抽取。（ii）独立化学体系：UConn-ILCC NMC/Gr 数据集[31]（44 个电芯，11 种循环工况）采用相同的 100 s 脉冲协议；为保持可比，只使用 20%、50% 和 90% 三个名义 SOC，得到 1,336 个电芯-RPT 组共 8,016 条记录（SOH 41.2~100%），并以 5 折电芯互斥划分（种子 42）运行原实现的完全相同流程；由于直流内阻在 NMC 上未进入任何一折所选的 50 项特征，A1 按其定义将直流内阻单独加入输入。针对内阻较高的 NMC 电芯，仅将式（2）中的电压单步跳变上限和极差上限分别放宽至 0.3 V 和 0.8 V，放宽后未剔除任何记录。（iii）稳健性：在已训练模型固定的条件下，对测试电芯的循环数施加 $\pm 10\%$ 的偏差；另在特征提取前向全部电压加入 $\sigma_{\text{noise}} = 1$ 或 2 mV 的零均值高斯噪声，且每个模型均在含噪数据上重新训练（匹配噪声）。（iv）在全部工况组合上，将每次 RPT 参与平均的脉冲数从 1 个变化到 6 个。（v）以积分梯度[50]将 R0 的预测归因到各波形采样点，并以参数量、浮点运算次数（FLOPs）和单线程 CPU 时延量化部署开销。除（ii）外，上述实验基于该实验协议的独立 CPU 复现实现完成。在原始 5 折划分下，复现实现得到的 R0、A2 和 GBDT 的 RMSE 分别为 1.427、1.474 和 1.028 个百分点（原实现分别为 1.377、1.500 和 1.022 个百分点），4.6 节的全部比较均在复现实现内部进行（补充说明 S6）。

3.6 评价指标与统计检验

同一 RPT 的六条工况记录共用一个容量标签，不能作为独立样本处理。对电芯 i 、RPT r 和初始 s ，先将六个工况的预测平均为 $\bar{y}_{irs}$ ；再计算每个电芯跨其全部 RPT 的 RMSE，并对种子和电芯取平均：

$$e_{is} = \sqrt{\frac{1}{R_i} \sum_{r=1}^{R_i} (\bar{y}_{irs} - y_{ir})^2}, RMSE = \frac{1}{NS} \sum_{i=1}^N \sum_{s=1}^S e_{is} \quad (14)$$

式中， R_i 为电芯 i 的 RPT 数， $N=64$ ， $S=3$ 。平均绝对误差（MAE）按相同方式聚合，误差单位统一为 SOH 百分点（pp）。不确定性采用 5,000 次按外层折分层的电芯自助重采样估计，并保持同一电芯在不同模型间的配对关系。配对差定义为 $\Delta RMSE = RMSE_{\text{候选}} - RMSE_{\text{参照}}$ ，负值表示候选模型更优； p 值来自 5,000 次双侧配对符号翻转随机化检验。在 9 个预先规定的检验族内实施 Holm 校正，显著性水平 $\alpha = 0.05$ （补充说明 S4）；分层分析、偏差分析、边际效应分析与事后分析均为描述性分析。区间估计以固定的数据划分和已训练模型为条件。

4 结果与讨论

除特别说明外，RMSE 和 MAE 均按式（14）计算，区间均为 95%折分层电芯 bootstrap 区间，“改善电芯”指配对比较中误差更低的电芯数。

4.1 编码器组合与组合依赖

在 15 种编码器组合中，R0（MLP 主干+PatchTST 补充）的 RMSE 最低，为 1.377 个百分点（1.247~1.513），MAE 为 1.141 个百分点（表 4、图 3a）。相对 MLP 主干+CNN 补充组合，R0 的 RMSE 降低 0.131 个百分点（-0.160~-0.101；Holm 校正后 $p = 0.003$ ），降幅为 8.7%，64 个电芯中 51 个改善。排名第二的 ResNet 主干+MLP 补充为 1.397 个百分点，比 R0 高 0.020 个百分点；由于并未对全部组合作两两检验，本文不将最低观测均值解释为显著优于所有候选。R0 在验证电芯上同样排名第一（1.310 个百分点），且验证与测试的前三名组合及其次序一致；在五个测试折中，R0 的名次依次为第 8、1、1、1 和 3。

在单因子层面，FT-Transformer 主干的误差相对 MLP 平均升高 0.147 个百分点（0.107~0.191），而 ResNet 与 MLP 之间未检出差异；各波形编码器的平均效应较小（相对 CNN 为 -0.041~-0.011 个百分点）。然而，补充编码器的排序取决于主干（图 3b）。PatchTST 在 MLP 主干下误差最低，在 ResNet 与 FT-Transformer 主干下却排末位；后两种主干分别以 MLP 补充和逐点 Transformer 补充的误差最低。以 MLP 主干+CNN 补充为双参照，8 个差中差均为正（ResNet 一侧为 0.061~0.140 个百分点，FT-Transformer 一侧为 0.098~0.174 个百分点；未校正 $p \leq 0.0022$ ），说明补充编码器相对 CNN 的优势在更换主干后缩小或反转。

对 3×5 组合的 RMSE 表作平方和分解，主干、补充编码器及二者的组合依赖分别占组间差异的 84.4%、3.8%和 11.8%（图 3c）。去掉 FT-Transformer 一行后，三者分别为 0.1%、52.3%

和 47.6%；因此，表面上的“主干占主导”反映的是 FT-Transformer 的较高误差，而组合依赖项在两种情况下均不可忽略。由此，编码器应依据受控比较证据按组合选择，而非依据架构复杂度；这与 BMS 对轻量、可解释模型的偏好相一致[18,27]，也支持选用 MLP 主干与 PatchTST 补充的组合。




图 3 编码器比较矩阵的主效应与组合依赖。(a) 15 种组合的电芯宏平均 RMSE；发散色标以只含主干的模型 A2（1.500 个百分点）为中点，蓝色表示误差更低，红色表示更高；方框标出 R0。(b) 交互作用图；折线不平行表示存在组合依赖；虚线为 A2。(c) 主干、补充编码器及组合依赖在组合间平方和中所占的比例：全部 15 种组合（95% 区间：73.1~90.2%、1.9~8.1%、7.3~20.2%）及去掉 FT-Transformer 后（0.0~4.6%、40.4~65.0%、34.1~58.4%），区间来自 5,000 次折分层电芯 bootstrap。数值为 225 次训练的种子平均电芯指标。

表 4 全部 15 种编码器组合的误差（SOH 百分点）

人工特征主干	波形补充	排名	RMSE	95%置信区间	MAE	验证 RMSE (排名)	Δ RMSE ^a	Holm <i>p</i>
MLP	PatchTST	1	1.377	1.247~1.513	1.141	1.310 (1)	-0.131	0.003
MLP	MLP	3	1.408	1.271~1.553	1.154	1.321 (3)	-0.100	0.003
MLP	逐点 Transformer	4	1.411	1.276~1.546	1.164	1.341 (5)	-0.098	0.003
MLP	TCN	6	1.437	1.294~1.585	1.175	1.356 (8)	-0.072	0.003
MLP	CNN	10	1.509	1.368~1.655	1.249	1.408 (10)	—	—
ResNet	MLP	2	1.397	1.258~1.548	1.152	1.312 (2)	-0.111	0.003
ResNet	TCN	5	1.433	1.296~1.581	1.186	1.332 (4)	-0.075	0.003
ResNet	CNN	7	1.437	1.304~1.578	1.200	1.367 (9)	-0.072	0.003
ResNet	逐点 Transformer	8	1.441	1.303~1.583	1.199	1.355 (7)	-0.068	0.003
ResNet	PatchTST	9	1.445	1.309~1.592	1.200	1.352 (6)	-0.064	0.003

人工特征主干	波形补充	排名	RMSE	95%置信区间	MAE	验证 RMSE (排名)	Δ RMSE ^a	Holm p
FT-Transformer	逐点 Transformer	11	1.555	1.406~1.709	1.303	1.495 (12)	+0.046	0.103
FT-Transformer	CNN	12	1.555	1.404~1.710	1.305	1.482 (11)	+0.046	0.093
FT-Transformer	MLP	13	1.573	1.420~1.731	1.315	1.495 (13)	+0.065	0.038
FT-Transformer	TCN	14	1.597	1.448~1.758	1.333	1.518 (14)	+0.089	0.003
FT-Transformer	PatchTST	15	1.598	1.446~1.757	1.340	1.525 (15)	+0.089	0.003

^a 该组合减 MLP 主干+CNN 补充组合，负值表示误差更低。Holm p 值对应 14 个组合相对 MLP 主干+CNN 补充的比较，不对应组合之间的两两比较。验证 RMSE 为 15 次运行在验证电芯上最优轮次误差的均值。

4.2 人工特征主干之上的波形增量

在 MLP 主干之上加入 PatchTST 分支，可降低同一批测试电芯上的误差（表 5、图 4a）。R0 相对 A2 降低 0.123 个百分点（ $-0.141 \sim -0.103$ ；Holm 校正后 $p < 0.001$ ），64 个电芯中 58 个改善，配对效应量 $d_z = -1.55$ 。相对不含人工特征主干的 A1，R0 降低 0.117 个百分点（ $-0.187 \sim -0.033$ ；Holm 校正后 $p = 0.002$ ），64 个电芯中 50 个改善，但电芯间差异更大（ $d_z = -0.36$ ，图 4b）。A1 与 A2 之间未检出差异（ -0.006 个百分点， $-0.091 \sim 0.065$ ； $p = 0.91$ ）；由于 A1 仍含匹配工况直流内阻与 τ ，这并非纯波形与纯人工特征的比较。因此，两种表征在平均意义上是互补的。

表 5 人工特征主干、波形补充、累计循环数与单调惩罚的消融结果（SOH 百分点）

配置	输入与约束	RMSE	MAE	对比	Δ RMSE	95%置信区间	Holm p	改善电芯
A2	人工特征主干+ τ , $\lambda = 0.1$	1.500	1.244	—	—	—	—	—
R0	人工特征主干+PatchTST+ τ , $\lambda = 0.1$	1.377	1.141	R0 - A2	-0.123	-0.141~-0.103	<0.001	58/64
A1	PatchTST+DCIR+ τ , $\lambda = 0.1$	1.494	1.259	R0 - A1	-0.117	-0.187~-0.033	0.002	50/64
A3	同 R0, $\lambda = 0$	1.406	1.164	R0 - A3	-0.028	-0.038~-0.018	<0.001	46/64
A4	同 A3, 去掉 τ	1.983	1.718	A3 - A4	-0.578	-0.731~-0.421	<0.001	52/64

Δ RMSE 为各对比中前者减后者；改善电芯为前者误差更低的电芯数。四项对比为预先规定的确证性检验，并在这四项内实施 Holm 校正。

这种增量并非所有波形编码器都能实现（表 6、图 4c）。固定 MLP 主干后，加入 PatchTST、MLP、逐点 Transformer 和 TCN 补充可使 RMSE 分别降低 0.123、0.092、0.089 和 0.063 个百分点（Holm 校正后 p 均 < 0.001 ），而加入 CNN 补充的变化为 +0.009 个百分点（ $-0.012 \sim 0.028$ ；Holm 校正后 $p = 0.491$ ）。PatchTST 的观测降幅最大，与其在 4.1 节中的排名一致。

表 6 各波形补充相对 MLP 主干 A2 的增量（SOH 百分点）

波形补充	双分支 RMSE	Δ RMSE	95%置信区间	相对变化	Holm p	改善电芯	d_z
PatchTST	1.377	-0.123	-0.141~-0.104	-8.2%	<0.001	58/64	-1.55
MLP	1.408	-0.092	-0.109~-0.074	-6.1%	<0.001	55/64	-1.14

波形补充	双分支 RMSE	Δ RMSE	95%置信区间	相对变化	Holm p	改善电芯	d_z
逐点 Transformer	1.411	-0.089	-0.109~-0.070	-5.9%	<0.001	54/64	-0.97
TCN	1.437	-0.063	-0.089~-0.037	-4.2%	<0.001	45/64	-0.56
CNN	1.509	+0.009	-0.012~0.028	+0.6%	0.491	28/64	+0.09

Δ RMSE 为双分支模型减 A2（1.500 个百分点）； d_z 为逐电芯差值均值除以其标准差。Holm 校正覆盖这五项比较。




图 4 人工特征主干与波形补充的作用。(a) 64 个测试电芯的逐电芯 RMSE 差 $R0 - A2$ （种子平均），按升序排列；蓝色柱表示 $R0$ 误差更低，红色柱表示更高；虚线与灰带为平均差及其 95% 区间。(b) 同(a)，为 $R0 - A1$ ；最右侧一柱为电芯 3。(c) 左：MLP 主干加入各补充后误差降低（蓝）或升高（红）的电芯数，以及 $A1$ 相对 $A2$ 的情况（虚线下方）；浅色表示差异不显著。右：64 个配对差的小提琴图与箱线图（箱体为四分位距，线为中位数，须线延伸至 1.5 倍四分位距，菱形为均值）；超出坐标范围的一个值（ $A1 - A2$ ，-1.72 个百分点，电芯 3）标于左侧边缘。

4.3 波形增量的分布与偏差修正

波形增量在不同 SOH 区间的幅度不同，但在六个脉冲工况中方向一致（补充表 S4、图 5b）。SOH 低于 80% 时， $R0$ 相对 $A2$ 的误差降低 0.413 个百分点（17.2%，62/64 个电芯改善）；SOH 在 95% 以上时降低 0.148 个百分点（15.5%，61/64）；90~95% 区间的增益最小（0.027 个百分点，36/64）。六个工况的降幅为 0.085~0.139 个百分点；在 384 个电芯-工况单元中，313 个（81.5%）误差降低，29 个电芯在全部六个工况下均改善，11 个循环工况组的平均差均为负（-0.029~-0.186 个百分点）。因此，每个单一脉冲工况均能从波形补充中获益，这对只能施加一次脉冲的部署场景具有实际意义。

分箱偏差分析表明，波形增量部分修正了人工特征主干的收缩偏差（图 5a）。在 2,823 个电芯-RPT 点上， $A2$ 在 SOH 低于 78% 时平均高估 3.25 个百分点，在 98~100% 时平均低估 1.41 个百分点； $R0$ 将二者分别降至 2.74 与 1.16 个百分点。从 $A2$ 到 $R0$ 的预测改变量随真实 SOH 增大

（斜率为 0.034 个百分点/百分点，0.031~0.036），并在约 92.1%处过零：低 SOH 端预测下调，高 SOH 端预测上调，与 A2 偏差的方向相反。因此，68.0%的点更接近实测值，预测 SOH 对真实 SOH 的回归斜率由 0.848 增至 0.882，总平方误差下降 14.4%。




图5 波形补充对偏差的修正及其在工况与电芯间的分布。(a) 上：按实测 SOH 每 2 个百分点分箱（低于 78%的箱合并）的平均偏差（预测减真实值），灰色为 A2，蓝色为 R0；阴影表示被修正的偏差。下：2,823 个电芯-RPT 点上 R0 - A2 的预测改变量（蓝色表示更接近实测值，红色表示更远离），以及最小二乘拟合及其 95% bootstrap 区间带。预测均对种子和工况取平均。(b) 左：六个工况及全部记录上的逐电芯 R0 - A2 RMSE 差（电芯按循环工况组排列；超出 ± 0.3 个百分点者颜色饱和）。右：各行的电芯宏平均差；所有 95%区间均不含零。

4.4 学习器依赖与参照方法对照

与参照方法的比较界定了双分支设计起作用的范围（表 7；全部结果见补充表 S5）。复现的 Nowacki 等[28]原始脉冲模型 RMSE 为 1.628 个百分点，R0 比其低 0.251 个百分点（Holm 校正后 $p = 0.019$ ）；由于该模型只使用原始脉冲且不含 τ ，此差距不能单独归因于双分支结构。在与 A2 相同的输入上，GBDT 和 RBF-SVR 的 RMSE 分别为 1.022 和 1.026 个百分点。A2 与 GBDT 输入相同，误差却相差约 0.48 个百分点，说明主干学习器的选择在本数据上影响较大。只用 τ 的模型误差约为 3 个百分点，不含 τ 的 GBDT 为 1.663 个百分点，说明循环记录与脉冲特征均有贡献。

表7 代表性方法的输入与电芯宏平均误差（SOH 百分点）

模型	输入	RMSE	95%置信区间	Δ RMSE (相对 A2)	Δ RMSE (相对 R0)	Holm p^a	优于 R0 的电芯
R0 (本文)	人工特征+ τ + ΔV	1.377	1.247~1.513	-0.123	—	—	—
A2 (仅主干)	人工特征+ τ	1.500	1.365~1.637	—	+0.123	<0.001	6/64
Nowacki 等[28] (复现)	原始 ΔV	1.628	1.454~1.820	+0.128	+0.251	0.019	17/64
GBDT	人工特征+ τ	1.022	0.897~1.160	-0.478	-0.355	0.006	58/64
RBF-SVR	人工特征+ τ	1.026	0.915~1.146	-0.474	-0.351	0.006	57/64

^a 相对 R0。R0 与 A2 的比较属于表 5 的预设检验族，其余比较属于含 30 项比较的扩展检验族（补充说明 S4）。

波形增量未能延续到 GBDT 主干上（图 6）。神经网络主干的增益为 0.123 个百分点（64 个电芯中 58 个改善），而 $(G+R0) - (G+A2)$ 仅为-0.008 个百分点，64 个电芯中 36 个改善（Holm 校正后 $p = 0.35$ ）；三个残差学习器均未显著改善 GBDT，直接向 GBDT 追加原始波形同样没有收

益（补充说明 S5）。这一规律与如下解释相一致：波形分支补回了神经网络主干未能从人工特征中利用的信息，而树集成模型已能提取这些信息。因此，实际应用中的准则是：采用神经网络人工特征主干时应加入波形补充，例如在需要端到端可微以施加导数约束的场合；而调优良好的树集成模型可直接依赖人工特征。




图 6 波形增量随主干学习器的变化。64 个测试电芯加入波形后电芯 RMSE 的配对变化（负值表示误差降低）。上：神经网络主干， $R0 - A2$ 。下：以 GBDT 为主干、通过残差网络加入波形， $(G+R0) - (G+A2)$ 。圆点为电芯，小提琴为分布，箱体为四分位距及中位数，菱形为均值。图中标注平均差、改善电芯数及 Holm 校正后 p 值。

4.5 设计因素的贡献

4.5.1 累计循环信息与单调惩罚

在各消融因素中，移除累计循环数造成的误差增幅最大（表 5、图 7a~c）。两模型均不使用单调惩罚时，保留 τ 的 A3 比去掉 τ 的 A4 低 0.578 个百分点（误差降低量区间 0.421~0.731；Holm 校正后 $p < 0.001$ ），64 个电芯中有 52 个改善，即去掉 τ 使误差增加约 41%。结合只用 τ 的模型误差仍较大的结果（4.4 节），循环记录是重要输入，但不能单独完成估计。

单调软约束带来的精度收益较小（图 7d~f）： $R0$ 比 A3 低 0.028 个百分点（误差降低量区间 0.018~0.038；Holm 校正后 $p < 0.001$ ），64 个电芯中有 46 个改善。预测对 τ 的偏导为正的比率（A3 为 5.39%， $R0$ 为 5.61%）以及同一电芯、同一工况下相邻 RPT 预测上升的比例（分别为 26.88%和 27.03%）基本不变，因此该惩罚起的是正则化作用，而不能保证退化轨迹单调。




图 7 累计循环信息与单调惩罚的作用。上排：A4（无循环数输入）与 A3（有循环数输入）的比较，两者均不使用惩罚。下排：A3（无惩罚）与 R0（有惩罚）的比较。（a, d）RMSE；（b, e）MAE；（c, f）相邻 RPT 间预测上升的比例。误差分布包含 64 个测试电芯（在初始化种子间平均）；上升率在同一电芯、名义 SOC 和脉冲方向内计算，涵盖 15 次运行。小提琴为限制在观测范围内的核密度；散点为观测值，菱形为均值。上下两排采用不同的纵轴范围。

4.5.2 波形分支的设计

在 2×2 片段网格中，R0 的(9, 4)配置误差最低（表 8；补充图 S1）。P1(5, 2)、P2(5, 4)和 P3(9, 2)分别使 RMSE 增加 0.072、0.094 和 0.055 个百分点（Holm 校正后 $p < 0.001$ ），且片段长度与步长存在交互作用：长度为 9 时步长 4 更优，长度为 5 时则步长 2 更优（差中差为 -0.077 个百分点，区间 -0.100 ~ -0.054）。三项适配中，均值池化头得到明确支持：还原为展平预测头（D1）使误差增加 0.062 个百分点（0.036 ~ 0.089；Holm 校正后 $p < 0.001$ ），同时参数量增加一倍以上（由 19,041 增至 42,593）。加入 RevIN（D2，-0.020 个百分点，-0.049 ~ 0.005）或采用原始电压（D3，+0.007 个百分点，-0.005 ~ 0.017）均未检出差异（Holm 校正后 p 均为 0.345）。以 A2 为共同参照，六种 PatchTST 变体均使误差降低 0.028 ~ 0.143 个百分点（64 个电芯中 40 ~ 57 个改善），说明该增量并不局限于单一片段设置。

表8 PatchTST 片段参数与适配消融结果（SOH 百分点）

配置	与 R0 的差别	RMSE	95%置信区间	参数量	Δ RMSE	Δ RMSE 的 95%置信区间	Holm p	R0 更优的电芯
R0	片段(9, 4), 均值池化头, 不用 RevIN, ΔV 输入	1.377	1.247~1.513	19,041	—	—	—	—
P1	片段(5, 2)	1.449	1.315~1.585	19,713	+0.072	0.050~0.094	<0.001	51/64
P2	片段(5, 4)	1.472	1.341~1.611	18,945	+0.094	0.080~0.109	<0.001	56/64
P3	片段(9, 2)	1.432	1.297~1.570	19,777	+0.055	0.038~0.071	<0.001	47/64
D1	展平预测头	1.440	1.304~1.585	42,593	+0.062	0.036~0.089	<0.001	46/64
D2	加入 RevIN	1.357	1.229~1.491	19,043	-0.020	-0.049~0.005	0.345	28/64
D3	原始电压输入	1.384	1.253~1.518	19,041	+0.007	-0.005~0.017	0.345	41/64

Δ RMSE 为该配置减 R0，正值表示 R0 的对应设计有益。片段配置（P1~P3）与适配消融（D1~D3）分属两个检验族，各自在 3 项比较内实施 Holm 校正。

4.5.3 人工特征数量

在当前候选集内，结果支持采用 $K=50$ （补充表 S6、补充图 S2）。 $K=10$ 、20 和 30 分别使 RMSE 增加 0.139、0.122 和 0.091 个百分点（Holm 校正后 $p=0.001$ ）， $K=75$ 和 100 略差（+0.037 和 +0.041 个百分点；Holm 校正后 $p=0.002$ ），而 $K=144$ 与 $K=50$ 之间未检出差异（-0.002 个百分点，区间 -0.019~0.015；Holm 校正后 $p=0.838$ ），参数量却多 31.6%。因此， $K=50$ 是兼顾精度与输入规模的折中选择。

4.6 泛化性、稳健性与部署

除 NMC/石墨数据集采用原实现外，本节实验采用 3.5.5 节所述的 CPU 复现实现。该实现完全复现了数据清洗结果，所得误差也与报告值高度接近，并再现了波形增量的符号与显著性（ $R0 - A2 = -0.046$ 个百分点，区间 -0.070~-0.023； $p < 0.001$ ；64 个电芯中 42 个改善）以及估计效果最好与最差的电芯（分别为电芯 12 和 3）。以下比较均在该实现内部进行（表 9、图 8）。

未见循环工况。将各循环工况组整体留出时，神经网络模型的误差仅温和上升（R0 由 1.427 增至 1.560 个百分点，+9.3%；A2 为 +8.2%），而 GBDT 的误差显著上升（由 1.028 增至 1.401 个百分点，+36.2%），GBDT 相对 R0 的优势因此由 0.40 缩小至 0.16 个百分点（图 8a）。在最难外推的第 3 组工况上，R0 比 GBDT 的误差低 0.59 个百分点。波形增量在未见工况下依然存在（ $R0 - A2 = -0.035$ 个百分点，区间 -0.053~-0.015； $p=0.008$ ；64 个电芯中 39 个改善），且在 11 个留出组中有 7 组 R0 的组均误差低于 A2。

独立化学体系。在 NMC/石墨数据集上（原实现，5 折×3 个种子），R0 的电芯宏平均 RMSE 为 1.968 个百分点（95%置信区间 1.728~2.236），A2 为 2.132 个百分点： $R0 - A2 = -0.163$ 个百分点（Holm 校正后 $p=0.0004$ ），44 个电芯中 39 个改善，误差降低 7.6%，与 LFP 上的 8.2% 相近，且在 5 个外层折和 3 个初始化种子中均为负值；去掉人工特征主干的 A1 为 2.468 个百分点。因此，波形增量在第二种电极体系上得到重复验证。与 LFP 相同，GBDT 在该数据上更准确（0.965 个百分点，44 个电芯中 43 个），且差距大于 LFP，主要来自神经网络在 SOH 两端的收

缩偏差：SOH 低于 60%时 R0 平均高估 3.3 个百分点（GBDT 为 1.0 个百分点），SOH 不低于 95% 时平均低估 1.75 个百分点；波形分支同样减小了低 SOH 端的高估（A2 为 4.1 个百分点）。只用 τ 的 GBDT 误差为 8.8 个百分点，而只用脉冲特征、不含 τ 的 GBDT 为 1.28 个百分点，表明 NMC 上的 SOH 信息主要来自脉冲本身。

波形分支补充的信息。 NMC 的开路电压曲线具有斜率，容量衰减使脉冲时的实际 SOC 偏离名义值，因而脉冲前电压本身随 SOH 变化：六种工况下其与 SOH 的 Spearman 相关系数绝对值平均为 0.93，而 LFP 仅为 0.36。波形分支输入的是首点作差电压 ΔV ，不含这一绝对电压水平，补充的是脉冲过程中的动态响应。若主干特征包含脉冲前电压、电压分位数等绝对电压水平量，两路信息会部分重叠：在复现实现中，主干含这类特征时 NMC 上的波形增量消失（+0.004 个百分点），将其从候选特征中移除后增量恢复为 -0.158 个百分点（区间 -0.205 ~ -0.112， $p < 0.001$ ，44 个电芯中 36 个改善），与原实现的结果一致（补充说明 S6）。由此可见，波形分支提供的是绝对电压水平之外的动态信息，而非重复人工特征已有的内容。

循环数误差与传感器噪声。 循环数存在 $\pm 10\%$ 的系统误差时，R0 的误差仅增加 1.5% ~ 3.5%（1.449 和 1.477 个百分点），而 GBDT 增加 8.6% ~ 14.4%（1.117 和 1.176 个百分点），且波形增量依然存在（-0.048 和 -0.041 个百分点； $p \leq 0.002$ ）（图 8b）。在训练与测试数据中加入匹配的传感器噪声时，精度平缓下降： $\sigma_{\text{noise}} = 1$ 和 2 mV 时，R0 的误差分别为 1.620 和 1.715 个百分点（+13.5%和+20.2%），GBDT 则为+33.5%和+38.5%（1.372 和 1.424 个百分点），波形增量依然保持（-0.058 个百分点，64 个电芯中 50 个改善；-0.045 个百分点，64 个电芯中 46 个改善； $p \leq 0.002$ ）。

脉冲数。 每个 RPT 仅用单个脉冲时，R0 在六种工况上的平均误差为 1.549 个百分点（1.490 ~ 1.582 个百分点）；使用两个和三个脉冲时分别为 1.477 和 1.453 个百分点，使用全部六个脉冲时为 1.427 个百分点（图 8c），且在各脉冲数下 R0 的误差均低于 A2。仅用三个充电脉冲即可达到 1.432 个百分点，与完整协议相差不超过 0.005 个百分点；因此诊断时间可减半，且这些脉冲可如文献[16]针对车辆所提出的那样在充电过程中施加。

归因。 积分梯度显示，R0 的波形归因几乎均匀地分布于整个响应：C/5、1C 和静置段中每个采样点的平均绝对归因分别为 0.0132、0.0138 和 0.0135 个百分点，六种工况的分布形态相同（图 8d）。因此，波形补充利用的是整个瞬态的形状，而非某个可由单一人工描述量单独刻画区段，这与其捕捉跨区段信息的预期作用一致。

计算开销。 R0 共有 19,041 个参数（以 32 位浮点数存储为 74 kB），每个脉冲需 0.42 MFLOPs，其中大部分来自波形分支（A2 为 13.7 kFLOPs）。在单个 CPU 线程上，PyTorch 单次推理耗时 0.52 ms，全部 143 项波形特征提取的 Python 参考实现耗时 6.5 ms，二者相对 100 s 的脉冲均可忽略；而经验证集选出的 GBDT 包含 1,000 棵树、共 61,000 个节点。这一资源占用与嵌入式 SOH 估计器所针对的规模处于同一量级[19]。

表9 复现实现中的泛化性与稳健性结果（电芯宏平均 RMSE，SOH 百分点）

场景	R0	A2	GBDT	R0 - A2	95%置信区间	p	改善电芯
五折电芯互斥（参照）	1.427	1.474	1.028	-0.046	-0.070~-0.023	<0.001	42/64
留一工况组验证	1.560	1.594	1.401	-0.035	-0.053~-0.015	0.008	39/64
循环数+10%（仅测试）	1.449	1.497	1.117	-0.048	-0.072~-0.024	<0.001	43/64
循环数-10%（仅测试）	1.477	1.518	1.176	-0.041	-0.063~-0.018	0.002	39/64
匹配噪声, $\sigma_{\text{noise}} = 1 \text{ mV}$	1.620	1.678	1.372	-0.058	-0.077~-0.040	<0.001	50/64
匹配噪声, $\sigma_{\text{noise}} = 2 \text{ mV}$	1.715	1.760	1.424	-0.045	-0.069~-0.022	0.002	46/64
每个 RPT 一个脉冲 ^a	1.549	1.574	1.203	—	—	—	—
每个 RPT 三个脉冲 ^a	1.453	1.494	1.066	—	—	—	—
三个充电脉冲	1.432	—	—	—	—	—	—

配对比较采用 5,000 次按外层折（或工况组）分层的电芯自助重采样与符号翻转检验；属描述性分析，未作多重比较校正。^a 全部工况组合的均值（分别为 6 种和 20 种）。




图8 泛化性、稳健性与归因（复现实现）。(a) 各循环工况组被留出时的组均 RMSE（留一工况组验证）；图例给出留一工况组验证下的电芯宏平均 RMSE，括号内为五折电芯互斥验证下的值。(b) 测试循环数存在 $\pm 10\%$ 偏差（模型固定）以及训练与测试数据中加入匹配高斯电压噪声（模型重新训练）时的 RMSE。(c) RMSE 随每个 RPT 参与平均的脉冲数的变化；折线为全部工况组合的均值，色带为其范围。(d) R0 在各波形采样点上的平均绝对积分梯度归因，实线为充电脉冲、虚线为放电脉冲，在测试记录、外层折与初始化种子间平均；阴影标示脉冲各区间。

4.7 误差特征与适用范围

整体平均偏差接近零，但掩盖了随 SOH 变化的误差（补充图 S3）。先平均每条记录的三个初始化预测，R0 在 16,938 条记录上的记录级 RMSE 为 1.461 个百分点、MAE 为 1.089 个百分

点、平均偏差为-0.093个百分点。SOH 低于 80%的 630 条记录平均高估 2.003 个百分点，SOH 在 95%以上的 5,682 条记录平均低估 0.574 个百分点（GBDT 分别为+1.068 和-0.130 个百分点）。不同电芯之间差异明显（补充图 S4）：按 R0 误差排第 1、22、43 和 64 位的电芯 12、6、44 和 3，误差分别为 0.526、0.961、1.519 和 3.568 个百分点（A2 分别为 0.704、1.066、1.723 和 3.624 个百分点）。11 个循环工况组的电芯宏平均 RMSE 为 0.878~2.333 个百分点（补充图 S5），第 3 组和第 6 组为正偏差，第 8 组为负偏差；各电芯衰减速率与平均偏差的相关系数为 0.59。

本分析在固定划分上以 64 个电芯为推断单位；低 SOH 高估有所减轻但未消除；由于基于差分和频谱的特征对训练中未出现的噪声较为敏感，训练数据应来自目标传感器（补充说明 S6）。在温度变化的实际运行数据及目标 BMS 硬件上的验证仍有待后续工作。

5 结论

本文基于 64 个公开 LFP/石墨电芯的 16,938 条短时脉冲记录，在统一的五折电芯互斥协议与训练预算下比较了 15 种编码器组合。主要结论如下：

（1）编码器应按组合评价。MLP 主干+PatchTST 补充（R0）的 RMSE 观测值最低（1.377 个百分点），较 MLP+CNN 组合低 8.7%，而 PatchTST 在另两种主干下均排末位；组合依赖项解释了组合间差异的 11.8%（去掉 FT-Transformer 后为 47.6%）。

（2）波形补充能够改进神经网络人工特征主干。R0 的 RMSE 比仅含主干的模型低 0.123 个百分点（8.2%），64 个电芯中 58 个改善；SOH 低于 80%时增益最大（17.2%），在六种脉冲工况下均一致改善，并部分校正了主干的收缩偏差。对于误差本已低至 1.022 个百分点的 GBDT 主干，加入波形未带来可测的增益。

（3）波形增量在独立 NMC/石墨数据集上得到重复（ $R0 - A2 = -0.163$ 个百分点，降低 7.6%，44 个电芯中 39 个改善），且其来源是绝对电压水平之外的动态响应。在复现实现中，波形增量在留出循环工况下（-0.035 个百分点）以及 1~2 mV 匹配传感器噪声下（-0.045~-0.058 个百分点）依然存在；在循环工况未见（+9%，而 GBDT 为+36%）或循环数存在 $\pm 10\%$ 偏差（至多+3.5%，而 GBDT 达+14.4%）时，神经网络模型的性能退化远小于 GBDT。

（4）在各消融因素中，累计循环数是影响最大的输入（去掉后误差增加 41%），单调惩罚则起温和的正则化作用（-0.028 个百分点）。片段配置(9, 4)与均值池化头（相对展平预测头误差 -0.062 个百分点，参数量少 55%）是最有效的设计选择， $K=50$ 则兼顾了精度与输入规模。

（5）模型足够轻量，适于嵌入式应用：参数量为 19,041（74 kB），每个脉冲 0.42 MFLOPs，单核推理为亚毫秒级；其归因分布于整个瞬态，且仅用三个充电脉冲即可达到六脉冲协议的精度，差距在 0.005 个百分点以内。

作者贡献声明 (CRediT)

[第一作者]: 概念构思、研究方法、软件、形式分析、写作——初稿。[第二作者]: 验证、可视化、写作——审阅与编辑。[通讯作者]: 指导、经费获取、写作——审阅与编辑。

利益冲突声明

作者声明, 不存在可能影响本文所报告工作的已知经济利益冲突或个人关系。

数据可用性

电池数据可从公开的 UConn-ISU-ILCC LFP 与 UConn-ILCC NMC 老化数据集[28,31]获取。清洗规则、输入定义、数据划分与评价指标见第 2、3 节及补充说明 S1~S6。【代码与衍生数据的公开仓库、版本及访问方式待作者补充。】

致谢

【资助来源与项目编号待补充。】

附录 A 补充材料

本文的补充材料（补充说明 S1~S6、补充表 S1~S7、补充图 S1~S5 及补充算法 S1）以单独文件提供。

参考文献

- [1] Berecibar M, Gandiaga I, Villarreal I, Omar N, Van Mierlo J, Van den Bossche P. Critical review of state of health estimation methods of Li-ion batteries for real applications. *Renew Sustain Energy Rev* 2016;56:572–87.
- [2] Xiong R, Li L, Tian J. Towards a smarter battery management system: a critical review on battery state of health monitoring methods. *J Power Sources* 2018;405:18–29. <https://doi.org/10.1016/j.jpowsour.2018.10.019>.
- [3] Wang Y, Guo S, Cui Y, et al. A comprehensive review of machine learning-based state of health estimation for lithium-ion batteries: data, features, algorithms, and future challenges. *Renew Sustain Energy Rev* 2025;224:116125. <https://doi.org/10.1016/j.rser.2025.116125>.
- [4] Zhu J, Wang Y, Huang Y, et al. Data-driven capacity estimation of commercial lithium-ion batteries from voltage relaxation. *Nat Commun* 2022;13:2261. <https://doi.org/10.1038/s41467-022-29837-w>.
- [5] Figgenger J, van Ouwerkerk J, Haberschus D, et al. Multi-year field measurements of home storage systems and their use in capacity estimation. *Nat Energy* 2024;9:1438–47. <https://doi.org/10.1038/s41560-024-01620-9>.
- [6] Pastor-Fernández C, Yu TF, Widanage WD, Marco J. Critical review of non-invasive diagnosis techniques for quantification of degradation modes in lithium-ion batteries. *Renew Sustain Energy Rev* 2019;109:138–59. <https://doi.org/10.1016/j.rser.2019.03.060>.
- [7] Bilfinger P, Rosner P, Schreiber M, et al. Battery pack diagnostics for electric vehicles: transfer of differential voltage and incremental capacity analysis from cell to vehicle level. *eTransportation* 2024;22:100356. <https://doi.org/10.1016/j.etrans.2024.100356>.
- [8] Roman D, Saxena S, Robu V, Pecht M, Flynn D. Machine learning pipeline for battery state-of-health estimation. *Nat Mach Intell* 2021;3:447–56. <https://doi.org/10.1038/s42256-021-00312-3>.
- [9] Zhang Y, Tang Q, Zhang Y, Wang J, Stimming U, Lee AA. Identifying degradation patterns of lithium ion batteries from impedance spectroscopy using machine learning. *Nat Commun* 2020;11:1706. <https://doi.org/10.1038/s41467-020-15235-7>.
- [10] Luo Z, Gao Z, Cai Z, et al. A review of on-board electrochemical impedance spectroscopy for low-cost in situ characterization technology. *J Energy Storage* 2026;141:119153. <https://doi.org/10.1016/j.est.2025.119153>.
- [11] Lin Y, Grosu C, Schreiber M, et al. Electrochemical impedance spectroscopy for onboard application: impact of the load conditions on the impedance relaxation behavior. *J Power Sources* 2025;654:237690. <https://doi.org/10.1016/j.jpowsour.2025.237690>.

- [12] Barai A, Uddin K, Widanage WD, McGordon A, Jennings P. A study of the influence of measurement timescale on internal resistance characterisation methodologies for lithium-ion cells. *Sci Rep* 2018;8:21. <https://doi.org/10.1038/s41598-017-18424-5>.
- [13] Li AG, Fahmy YA, Wu MM, et al. Fast time-domain impedance spectroscopy of lithium-ion batteries using pulse perturbation. In: 2022 IEEE Transportation Electrification Conference & Expo (ITEC); 2022, p. 155–60. <https://doi.org/10.1109/ITEC53557.2022.9813868>.
- [14] Birkel CR, Roberts MR, McTurk E, Bruce PG, Howey DA. Degradation diagnostics for lithium ion cells. *J Power Sources* 2017;341:373–86.
- [15] Barai A, Uddin K, Dubarry M, et al. A comparison of methodologies for the non-invasive characterisation of commercial Li-ion cells. *Prog Energy Combust Sci* 2019;72:1–31. <https://doi.org/10.1016/j.pecs.2019.01.001>.
- [16] Li AG, Wang W, West AC, Preindl M. Health and performance diagnostics in Li-ion batteries with pulse-injection-aided machine learning. *Appl Energy* 2022;315:119005. <https://doi.org/10.1016/j.apenergy.2022.119005>.
- [17] Tao S, Ma R, Zhao Z, et al. Generative learning assisted state-of-health estimation for sustainable battery recycling with random retirement conditions. *Nat Commun* 2024;15:10154. <https://doi.org/10.1038/s41467-024-54454-0>.
- [18] Li M, Xu W, Zhang S, et al. State of health estimation and battery management: a review of health indicators, models and machine learning. *Materials* 2025;18(1):145. <https://doi.org/10.3390/ma18010145>.
- [19] Kulkarni A, Teodorescu R. Computationally efficient machine-learning-based online battery state of health estimation. *arXiv* 2024. arXiv:2406.06151.
- [20] Das K, Kumar R. Electric vehicle battery capacity degradation and health estimation using machine-learning techniques: a review. *Clean Energy* 2023;7(6):1268–81.
- [21] Sylvestrin GR, Maciel JN, Ando Junior OH. Comprehensive feature extraction for battery health prognostics: identifying predictive indicators of state of health. *J Power Sources* 2026;668:239389. <https://doi.org/10.1016/j.jpowsour.2026.239389>.
- [22] Fu P, Chu L, Hou Z, et al. Transfer learning and vision transformer based state-of-health prediction of lithium-ion batteries. *arXiv* 2022. arXiv:2209.05253.
- [23] Li Y, Gao G, Chen K, et al. State-of-health prediction of lithium-ion batteries using feature fusion and a hybrid neural network model. *Energy* 2025;319:135163. <https://doi.org/10.1016/j.energy.2025.135163>.
- [24] Zhao Y, Geng L, Meng W, et al. Cross-attention-based hybrid feature fusion network for state-of-health estimation of lithium-ion batteries. *Sci Rep* 2026;16:17800. <https://doi.org/10.1038/s41598-026-48317-5>.
- [25] Jin P, Yang S, Xu X, et al. Multiview state-of-health estimation for lithium-ion batteries using time–frequency image fusion and attention-based deep learning. *PLoS One* 2025;20(11):e0335351. <https://doi.org/10.1371/journal.pone.0335351>.
- [26] Pandit R, Ahlawat N. A standardized comparative framework for machine learning techniques in lithium-ion battery state of health estimation. *Future Batteries* 2025;7:100099. <https://doi.org/10.1016/j.fub.2025.100099>.
- [27] Bairwa B, Pareek K, Jadoun VK. Cycle based state of health estimation of lithium ion cells using deep learning architectures. *Sci Rep* 2025;15:37078. <https://doi.org/10.1038/s41598-025-20995-7>.
- [28] Nowacki B, Ramamurthy J, Thelen A, Tischer C, Pint CL, Hu C. Rapid estimation of lithium-ion battery capacity and resistances from short duration current pulses. *J Power Sources* 2025;628:235813. <https://doi.org/10.1016/j.jpowsour.2024.235813>.
- [29] Tao S, Ma R, Chen Y, et al. Rapid and sustainable battery health diagnosis for recycling pretreatment using fast pulse test and random forest machine learning. *J Power Sources* 2024;597:234156. <https://doi.org/10.1016/j.jpowsour.2024.234156>.
- [30] Ran A, Cheng M, Chen S, et al. Fast remaining capacity estimation for lithium-ion batteries based on short-time pulse test and Gaussian process regression. *Energy Environ Mater* 2023;6:e12386. <https://doi.org/10.1002/eem2.12386>.
- [31] Nowacki B, Schmitt T, Aquino P, Hu C. Fine-tuning for rapid capacity estimation of lithium-ion batteries. *Energy Storage Mater* 2025;81:104425. <https://doi.org/10.1016/j.ensm.2025.104425>.
- [32] Jones PK, Stimming U, Lee AA. Impedance-based forecasting of lithium-ion battery performance amid uneven usage. *Nat Commun* 2022;13:4806. <https://doi.org/10.1038/s41467-022-32422-w>.
- [33] Lu J, Xiong R, Tian J, Wang C, Sun F. Deep learning to estimate lithium-ion battery state of health without additional degradation experiments. *Nat Commun* 2023;14:2760. <https://doi.org/10.1038/s41467-023-38458-w>.
- [34] Che Y, Lam VN, Rhyu J, et al. Diagnostic-free onboard battery health assessment. *Joule* 2025;9:102010. <https://doi.org/10.1016/j.joule.2025.102010>.
- [35] Sohail M, Tanveer M, Kim HS. Trustworthy machine learning and mathematical modelling for lithium-ion battery state-of-health estimation. *Mathematics* 2026;14(11):1879. <https://doi.org/10.3390/math14111879>.
- [36] Barua N, Collins MD, Islam MS, et al. Predictor structure modulates validation inflation and cell-transfer reliability in battery state-of-health estimation. *Batteries* 2026;12(9):342. <https://doi.org/10.3390/batteries12090342>.
- [37] Zhang H, Gui X, Zheng S, et al. BatteryML: an open-source platform for machine learning on battery degradation. In: International Conference on Learning Representations (ICLR); 2024.
- [38] Bai S, Kolter JZ, Koltun V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv* 2018. arXiv:1803.01271.

- [39] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need. In: *Advances in Neural Information Processing Systems* 30; 2017, p. 5998–6008.
- [40] Nie Y, Nguyen NH, Sinthong P, Kalagnanam J. A time series is worth 64 words: long-term forecasting with transformers. In: *International Conference on Learning Representations (ICLR)*; 2023. <https://openreview.net/forum?id=Jbdc0vTOcol>.
- [41] Gorishniy Y, Rubachev I, Khrulkov V, Babenko A. Revisiting deep learning models for tabular data. In: *Advances in Neural Information Processing Systems* 34; 2021, p. 18932–43.
- [42] Liu H, Li C, Hu X, et al. Multi-modal framework for battery state of health evaluation using open-source electric vehicle data. *Nat Commun* 2025;16:1137. <https://doi.org/10.1038/s41467-025-56485-7>.
- [43] Huang X, Tao S, Liang C, et al. iMOE: prediction of second-life battery degradation trajectory using interpretable mixture of experts. *Nat Commun* 2026;17:2549. <https://doi.org/10.1038/s41467-026-69369-1>.
- [44] Lu Z, Mo H, Wang Y. MSSformer: a model for accurate and stable state of health estimation of lithium-ion batteries. *Electr Power Syst Res* 2026;254:112661. <https://doi.org/10.1016/j.epsr.2025.112661>.
- [45] Tang P, Qiu Z, Yao Z, et al. Lithium-ion battery RUL prediction based on optimized VMD-SSA-PatchTST algorithm. *Sci Rep* 2025;15:26824. <https://doi.org/10.1038/s41598-025-11934-7>.
- [46] Labib KM, Rasool I, Ahmed S. Operator-theoretic and physics-guided sequence modeling of lithium-ion battery voltage dynamics. *arXiv* 2026. [arXiv:2605.01693](https://arxiv.org/abs/2605.01693).
- [47] Wang F, Zhai Z, Zhao Z, Di Y, Chen X. Physics-informed neural network for lithium-ion battery degradation stable modeling and prognosis. *Nat Commun* 2024;15:4332. <https://doi.org/10.1038/s41467-024-48779-z>.
- [48] Che Y, Zheng Y, Rhyu J, et al. Mechanistically guided residual learning for battery state monitoring throughout life. *Nat Commun* 2026;17:855. <https://doi.org/10.1038/s41467-025-67565-z>.
- [49] Guo W, Vilsen SB, Li Y, Verma A, Stroe DI, Brandell D. Uncovering the impact of battery design parameters on health and lifetime using short charging segments. *Energy Environ Sci* 2025;18:8462–74. <https://doi.org/10.1039/D5EE03268G>.
- [50] Sundararajan M, Taly A, Yan Q. Axiomatic attribution for deep networks. In: *Proceedings of the 34th International Conference on Machine Learning (ICML)*, PMLR 70; 2017, p. 3319–28.